

МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ПРОФЕССИОНАЛЬНОГО ОБРАЗОВАНИЯ
«МОСКОВСКИЙ ФИЗИКО-ТЕХНИЧЕСКИЙ ИНСТИТУТ
(государственный университет)»

ФАКУЛЬТЕТ УПРАВЛЕНИЯ И ПРИКЛАДНОЙ МАТЕМАТИКИ
КАФЕДРА «ИНТЕЛЛЕКТУАЛЬНЫЕ СИСТЕМЫ»

Построение системы поиска похожих опухолей с помощью глубоких сверточных сетей

Выпускная квалификационная работа
(бакалаврская работа)

Направление подготовки: 03.03.01 Прикладные математика и физика

Выполнил:

студент 474 группы _____ Макарчук Глеб Игоревич

Научный руководитель:

к.ф.-м.н. _____ Беляев Михаил Геннадьевич

Москва 2018

Аннотация

Построение эффективной системы поиска похожих опухолей мозга является актуальной проблемой. Каждый год в мире фиксируется порядка 80000 новых случаев первичных опухолей и более 200000 случаев метастатических опухолей головного мозга. Система поиска опухолей позволит врачам повысить точность диагностики заболеваний, даст возможность прогнозировать развитие болезней и планировать лечение на основе схожих случаев.

Исторически, в большинстве систем поиска похожих изображений использовались признаки сходства, которые задавались исследователями вручную. В последние несколько лет начинают появляться примеры работ, в которых извлечение признаков проводится автоматически с помощью глубоких нейронных сетей. При этом большинство систем основано на решении задачи классификации и последующем использовании найденного представления для введения метрики схожести.

В задаче поиска похожих изображений в радиохирургии есть не только информация о классе (типе) опухоли, но и ее контур, а также информация о локализации. Новизной работы является использование многозадачного обучения для автоматического извлечения признаков. В работе демонстрируется, что использование многозадачного обучения приводит к тому что представления содержат больше релевантной информации об опухолях. Также показывается, что в найденном пространстве низкой размерности удобно осуществлять поиск похожих случаев. Представленная система поиска была провалидирована врачами центра радиохирургии.

Оглавление

1	Введение	1
2	Задача и предложенный метод	3
2.1	Постановка задачи	3
2.1.1	Построение представления	3
2.1.2	Поиск похожих изображений	4
2.2	Обзор существующих методов	4
2.3	Данные	6
2.3.1	Типы опухолей	6
2.3.2	Описание данных	7
2.4	Описание предложенного метода	8
2.4.1	Задачи решаемые многозадачным обучением	9
3	Вычислительные эксперименты	11
3.1	Постановка экспериментов	11
3.1.1	Описание архитектуры нейронной сети	11
3.1.2	Описание процесса обучения сети	14
3.2	Результаты	14
3.2.1	Количественная оценка	14
3.2.2	Качественная оценка	17
4	Заключение	21

Глава 1

Введение

В последнее время, в связи с успехами развития глубоких нейронных сетей, эффективность машинного обучения в задачах анализа изображения возросла [1]. Сейчас сверточные сети позволяют с высокой точностью решать задачи классификации и сегментации. Этот прогресс благоприятно отразился на анализе медицинских изображений, где сверточные сети стали применять для автоматизации множества трудоемких задач таких как сегментация пораженных тканей [2], классификация различных типов тканей [3], обнаружение опухолей [4, 5].

Глубокие сверточные сети так эффективны благодаря, в частности, их способности автоматически извлекать признаковое описание объектов под решаемую задачу используя только пиксельное представление изображения. Таким образом, исследователю не нужно придумывать признаковое описание объектов вручную. Более того, согласно [6], такое представление часто позволяет добиться лучших результатов решения конкретной задачи. Способность глубоких сверточных сетей строить эффективные признаковые описания объектов на сегодняшний день используется при построении систем поиска схожих изображений и, в том числе, схожих медицинских изображений [5].

В большинстве современных систем поиска схожих медицинских изображений с помощью сверточных сетей решаются задачи классификации. Далее, представления взятые с последних слоев сети используются для последующего введения метрики схожести. Особенностью задачи поиска схожих изображений в радиохирургии является множественные критерии схожести и наличие различной разметки изображений. В частности, помимо класса (типа), опухоли мозга характеризуются контуром и локализацией. Цель данной работы состоит в построении системы поиска похожих опухолей головного мозга, которая бы учитывала различные критерии схожести.

Систему поиска предлагается строить с помощью представления опу-

хотей в пространстве низкой размерности, в котором удобно осуществлять поиск. При этом новизной работы является использование сетей полученных с помощью многозадачного обучения, что позволяет извлекать признаки содержащие больше релевантной информации об опухолях. Демонстрируется, что в полученном пространстве представлений низкой размерности удобно осуществлять поиск. Также в работе показывается что именно обучения сетей сразу на нескольких релевантных задачах дает наилучшие результаты.

Данные используемые в данной работе предоставлены врачами центра «Гамма-нож» на базе НИИ нейрохирургии им. Н.Н. Бурденко. Представленная система поиска была провалидирована врачами отделения.

Глава 2

Задача и предложенный метод

2.1 Постановка задачи

2.1.1 Построение представления

Пусть X - множество трехмерных массивов, которые представляют собой подобласть трехмерного МРТ изображения мозга содержащего опухоль в модальности T1 с контрастом. B - множество ограничительных рамок опухолей.

$$f_{repr} : X \times B \rightarrow \mathbb{R}^n \quad (2.1)$$

отображение изображения опухоли в ее n -канальное представление.

При этом представление $y \in \mathbb{R}^n$ должно обладать следующими свойствами: свойство полезных признаков и свойство близости.

Свойство полезных признаков

Представление $y \in \mathbb{R}^n$ опухоли $t \in X$ должно содержать информацию о различных релевантных характеристиках опухоли. Примеры характеристик опухолей:

1. Характерный линейный размер ($V^{1/3}$)
2. Тип опухоли (метастаза, менингиома, шваннома)
3. Локализация опухоли (анатомическая область мозга, левое-правое расположение и др.)

Технически, это значит что на тренировочной выборке можно обучить модель

$$f_K : \mathbb{R}^n \rightarrow K \quad (2.2)$$

такую, что она будет восстанавливать значения $k \in K$ на тестовой выборке с хорошим качеством, где K - конечное множество классов (для задачи классификации характеристики) или \mathbb{R} (для задачи регрессии характеристики).

Для оценки качества восстановления характеристики k предлагается использовать:

- Средний модуль ошибки - для задач регрессии
- Точность - для задач классификации

Свойство близости объектов

Это свойство отвечает за то что представления близких по форме и различным характеристикам опухолей должны находиться близко в смысле l_2 расстояния. То есть для похожих $t_1, t_2 \in X \times B$, расстояние $\|f_{repr}(t_1) - f_{repr}(t_2)\|_2$ должно быть мало.

2.1.2 Поиск похожих изображений

Для поиска похожего изображения решается задача ранжирования относительно некоторого фиксированного изображения.

Свойство близости объектов является ключевым для выдачи ранжирования, так как ранжирование относительно опухоли t_a в нашей постановке определяется следующим образом:

$$t_1 \prec t_2 \iff \|f_{repr}(t_1) - f_{repr}(t_a)\|_2 < \|f_{repr}(t_2) - f_{repr}(t_a)\|_2 \quad (2.3)$$

Качество ранжирования определяется с помощью:

- Количественной оценки, полученной с помощью анализа характеристик опухолей в поисковой выдаче. В качестве базовой оценки предлагается смотреть на оценки случайной выдачи.
- Качественной оценки, полученной с помощью разбора конкретных случаев работы системы. Разбор в том числе проводится врачами-экспертами.

2.2 Обзор существующих методов

До того как глубокие нейронные сети получили широкое распространение в анализе изображений, большинство систем поиска похожих медицинских изображений основывалось на представлении изображения неко-

торым набором вручную построенных признаков. Так, например, для построения системы поиска похожих изображений для данных *IRMA* [7], состоящих из 10000 различных радиографических изображений, в работе [8] в качестве признаков предлагается использовать $2D$ дискретные вейвлет-преобразования. Также в качестве признаков часто используются локальные и глобальные гистограммы интенсивности пикселей [9].

Поиск похожих $3D$ изображений осложняется большой размерностью этих изображений в сочетании с малыми объемами доступных для анализа выборок медицинских данных. В качестве подхода к снижению размерности исследовались пути сведения этой задачи к задаче поиска похожего $2D$ изображения [9].

Так, например, в системе *ASSERT* [10] для поиска легких со схожими патологиями, переход к $2D$ изображениям осуществлялся с помощью выбора ключевых срезов. При работе в системе, врач выбирал интересующие срезы трехмерного изображения и размечал на них области с патологией. Далее система извлекала из выделенных областей признаки, которые в дальнейшем использовались для поиска похожих случаев.

Пример еще одного способа перевода трехмерного изображения в пространство меньшей размерности можно увидеть в работе [11], где исследовался способ представлять МРТ изображение в виде графа. Каждое изображение представлялось графом, где вершины представляли собой интересующие области изображения, а ребра определяли соотношения между этими областями. Авторы определяли сходство изображений через подобие соответствующих графов, где подобие графов определялось как оценка числа модификаций необходимых для превращения одного графа в другой.

Современные методы поиска схожих изображений часто в том или ином виде используют сверточные нейронные сети для извлечения признаков из изображения [5]. Так, например, в [12] в качестве признаков брались значения на последнем полносвязном слое нейронной сети, решающей задачу классификации рентгеновского снимка.

В работе [13] исследовался способ создавать представления низкой размерности для трехмерных МРТ изображений. Используя значения на последних слоях нейронной сети создавались представления большой размерности. Далее с помощью хэширующих деревьев эта размерность понижалась.

Также существуют методы, которые создают представления напрямую решая задачу определения сходства изображений. Пример такой работы - [14], где авторы обучают сиамскую нейронную сеть построенную на основе архитектуры ResNet 50 [15]. Сеть учится оценивать подобие глазных яблок в клиническом смысле - относительно состояния патологии (ретинопатии). В качестве представления изображений глаз в работе использовались зна-

чения на последних слоях нейронной сети.

2.3 Данные

В работе используются данные пациентов центра «Гамма-нож» находящегося в НИИ нейрохирургии им. Бурденко, Москва. Этот центр - одно из немногих заведений в России в котором проводят операции радиотерапии на установке «Гамма-нож». Операции проводятся несколько сотням пациентов в год. Типичная процедура лечения состоит из сбора информации о пациенте, снятия МРТ снимка мозга, разметки опухолей, планирования лечения и облучения опухолей радиацией.

Самые частые типы опухолей в предоставленных данных - метастазы, менингиомы и шванномы. Порядка 77% пациентам центра ставится один из данных диагнозов. Согласно отчету Leksell Gamma Knife Society [16] схожая статистика наблюдается по всему миру для пациентов радиотерапии. В работе рассматривались именно эти диагнозы, так как для других диагнозов не было предоставлено достаточного количества снимков.

2.3.1 Типы опухолей

Метастазы

Метастатические опухоли головного мозга это вторичные опухоли которые возникают, когда раковые клетки распространяются из первичной опухоли в мозг. Эти опухоли - частое осложнения у больных раком и являются одной из основных причин смертности у таких больных. Ожидаемая продолжительность жизни при использовании поддерживающей терапии составляет всего 40-50 дней. Большинство случаев характеризуется множественными поражениями.

Менингиомы

Большинство менингиом это медленно растущие доброкачественные образования. Наиболее часто внутричерепные менингиомы располагаются парасagitтально и на фальксе. Типичная менингиома закруглена со стороны мозга и вытянута со стороны мозговой оболочки. По мере роста, опухоль оказывает давление на мозг и мешает нормальному функционированию мозга.

Шванномы

Шванномы, или невриномы - это доброкачественные опухоли которые растут из шванновских клеток, образующих миелиновую оболочку нервов. По мере роста, опухоль оказывает давление на слуховые и вестибулярные ткани слухового и лицевого нервов, вызывая потерю слуха и звон в ушах. Так же наблюдается потеря баланса. Когда опухоль увеличивается в размерах, она может оказать влияние на тройничный нерв и близлежащие структуры мозга, становясь опасной для жизни.





Рис. 2.1: Пример метастатической опухоли





Рис. 2.2: Пример менингиомы




Рис. 2.3: Пример шванномы

2.3.2 Описание данных

Было предоставлено 995 МРТ изображений мозга, из которых 404 - метастазы, 339 менингомы и 252 шванномы. Каждое изображение - 3D МРТ снимок мозга в модальности T1 с контрастом. Для каждого снимка врачи обозначили контуры опухолей и классифицировали их по типу и по локализации.

Локализация опухоли

Каждая опухоль характеризуется одним или несколькими классами локализации (Табл. 2.1). Анатомическая область является обязательным клас-

Область локализации	Количество классов	Наличие разметки
Анатомическая	12 классов	обязательно
Левая или правая	2 класса	опционально
Передняя или задняя	2 класса	опционально
Верхняя или нижняя	2 класса	опционально
Медиальная или латеральная	2 класса	опционально

Таблица 2.1: Разметка опухолей на классы локализации

сом. Остальные классы обозначались на усмотрение врачей.

Контуров опухоли

С точки зрения врача $3D$ изображение это набор $2D$ изображений срезов мозга. Процесс разметки контуров опухоли происходит следующим образом: для каждого среза, врач обозначает $2D$ контур, задавая его набором точек многоугольника. Совокупность контуров для всех срезов задает $3D$ контур опухоли.

2.4 Описание предложенного метода

Основной идеей предлагаемого метода является использование мультизадачного обучения 2.4. В процессе обучения, одновременно решаются сразу несколько релевантных задач классификации и сегментации.

При этом алгоритм учится выводить представление, содержащее информацию о различных характеристиках опухоли.

Многозадачное обучение

Многозадачное обучение (MLT) это парадигма при которой одновременно решаются несколько задач обучения, при этом используются общие черты и различия между задачами. Решение множества задач одновременно позволяет повышать качество решения основной задачи [17].

В данной работе одновременно решаются несколько задач классификации и сегментации. Эти задачи содержат релевантную информацию об опухолях, поэтому предполагается, что их одновременное решение приведет к нахождению представления опухолей, содержащего большее количество релевантной информации.

В случае многозадачного обучения для глубоких нейронных сетей, веса остова нейронной сети используются для решения нескольких различных задач. Далее, сеть делится на несколько голов, каждая из которых имеет

свои веса и решает свою задачу. При обучении процедура обратного распространения ошибки от функции потерь для каждой задачи модифицирует голову сетки для этой задачи и общий остов. Таким образом получается, что веса остова нейронной сети оптимизируются решением сразу нескольких задач. Схематически, структура сети приведена на Рис. 2.4

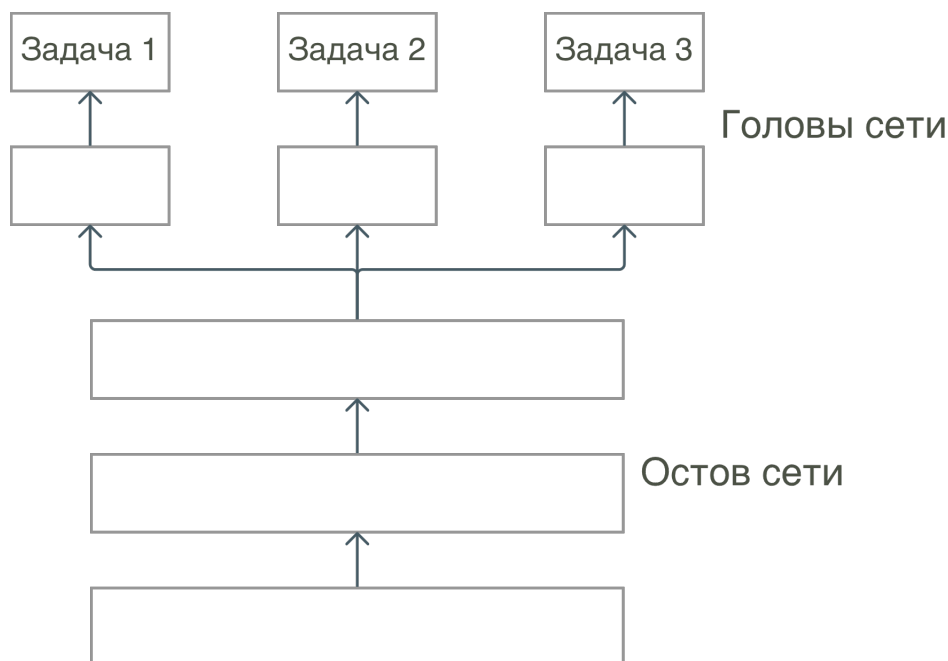


Рис. 2.4: Схема мультизадачного обучения для нейронной сети

2.4.1 Задачи решаемые многозадачным обучением

При обучении решаются задачи классификации и сегментации. В этом разделе определим данные задачи формально. Подробная схема используемой сети находится в разделе 3: Вычислительный эксперимент.

Задача сегментации

Пусть X - множество трехмерных массивов представляющих собой описание трехмерного МРТ изображения. Значения элементов массива x представляют собой интенсивности соответствующих пикселей.

Y - множество трехмерных массивов, где значения элементов это бинарная разметка, которая определяет имеется ли опухоль в вокселе. Размерности массива $x \in X$ и соответствующего ему $y \in Y$ совпадают.

Задача сегментации состоит в бинарной классификации каждого вокселя изображения на пораженную и не пораженную область. Соответствующие y для x размечают врачи с помощью обозначения контуров опухолей




Рис. 2.5: Иллюстрация среза МРТ изображения мозга




Рис. 2.6: Иллюстрация маски сегментации размеченной врачом

на $2D$ срезах мозга. С помощью вспомогательного инструментария контуры переводятся в бинарные маски.

Задача классификации

Пусть $t \in \mathbb{R}^n$ - признаковое описание опухоли. Пусть есть конечное множество классов K . При этом, есть некоторая неизвестная зависимость $y^* : \mathbb{R}^n \rightarrow K$, значения которой известны только на объектах обучающей выборки.

Тогда задача классификации заключается в построении функции

$$f_K : \mathbb{R}^n \rightarrow K \quad (2.4)$$

такой что она восстанавливает метки класса с высокой точностью для представлений произвольных опухолей $t \in \mathbb{R}^n$.

Глава 3

Вычислительные эксперименты

3.1 Постановка экспериментов

3.1.1 Описание архитектуры нейронной сети

Для решения данной задачи используется глубокая сверточная нейронная сеть на основе ResNet [15].

Сеть ResNet

Сеть ResNet состоит из множества ResBlock блоков 3.1. Экспериментально показано, что использование ResBlock позволяет строить очень глубокие сети, способные находить сложные зависимости. Это достигается из-за конструкции ResBlock, которая помогает справиться с проблемой затухания градиента [15]. На сегодняшний день, сети построенные на основе ResNet побеждают в конкурсах сегментации и классификации изображений [15].




Рис. 3.1: Схема ResBlock

Остов нейронной сети

Остов нейронной сети 3.2 состоит из двух путей - глобального (нижний) и локального (верхний). Цель локального пути заключается в создании признаков которые описывают локальный контекст и имеют малое рецептивное поле. Поэтому разрешение изображения не уменьшается и путь содержит относительно мало сверточных преобразований.




Рис. 3.2: Архитектура остова нейронной сети

Цель глобального пути - собрать признаки, которые содержат глобальную информацию. Поэтому с помощью децимации разрешение изображения уменьшается вдвое и далее следует большое число сверточных преобразований. Как следствие, признаки на выходе имеют большое рецептивное поле и содержат информацию о глобальном контексте. Далее пространственное разрешение восстанавливается к исходному с помощью интерполяции и происходит конкатенация глобальных и локальных признаков для получения единой карты признаков. Данная карта в дальнейшем используется для построения представления опухоли а также для использования различными головами нейронной сети.

Построение представления опухоли по карте признаков

Основной проблемой получения представления опухоли из карты признаков является то что вектор должен быть фиксированной длины, в то время как опухоли отличаются размерами. Чтобы решить эту проблему используется вариация слоя *RoiPool* [18].

Слой *RoiPool* выбирает максимальное значение по пространственным координатам опухоли для каждого канала признаков 3.3. Таким образом получается вектор фиксированной размерности равной числу каналов карты признаков.




Рис. 3.3: Схема RoIPool

Головы нейронной сети

Архитектуры голов для решения различных задач могут отличаться (Рис. 3.4). В частности в при решении нашей задачи, есть головы двух типов: классификационная и сегментационная.

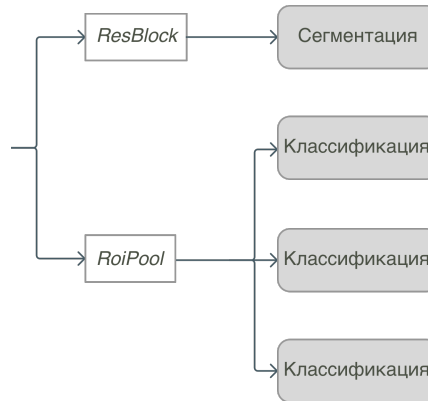


Рис. 3.4: Архитектура голов нейронной сети

Сегментация

Для решения задачи сегментации используется голова с одним ResBlock таким, что на выходе имеется один канал - разметка сегментации.

Полученная разметка сравнивается с реальной, считается потеря и с помощью процедуры обратного распространения ошибки обновляются веса данной головы и остова сети. В качестве функции потерь используется среднее значение *бинарной кросс-энтропии* по всем пикселям изображения [19]:

$$-\frac{1}{N} \sum_{n=1}^N [y_n \log(\hat{y}_n) + (1 - y_n) \log(1 - \hat{y}_n)] \quad (3.1)$$

где y_n - метка n -го вокселя изображения и $\hat{y}_n = P(y_n = 1)$.

Классификация

Головам нейронной сети, проводящим классификацию, на вход подаются представления опухолей полученных с помощью операции RoiPool. Представления проходят через один полносвязный слой и *Softmax* слой для получения вероятностей классов. В качестве функции потерь используется *кросс-энтропия*:

$$-\log(\hat{y}_i) \quad (3.2)$$

где \hat{y}_i предсказанная вероятность правильного класса.

3.1.2 Описание процесса обучения сети

Нейронная сеть обучалась в течение 120 эпох с шагом обучения уменьшающимся в 10 раз после 90 и 105 эпохи. Было выбрано 120 эпох так как далее значение функции потерь становилось постоянным и параметры сети переставали меняться.

В процессе обучения сети, мы использовали подобласти размера $120 \cdot 120 \cdot 120$ вместо изображений целиком. Необходимость использовать такие подобласти связана с техническим ограничением - недостаточным количеством памяти для подсчета обратного распространения ошибки на всем изображении целиком.

Функции потерь для различных задач были взвешены. Веса подбирались эвристически, а именно, веса задач классификации уменьшались до момента, пока суммарный функционал ошибки не начал убывать.

Обучение каждой модели занимало около суток. Анализ проводился на отложенной тестовой выборке - 20% от исходного количества снимков.

3.2 Результаты

3.2.1 Количественная оценка

Свойство полезных признаков

В постановке задачи упоминалось свойство необходимых признаков как одна из целей работы. То есть, для некоторой характеристики k должна существовать функция $f_K : \mathbb{R}^n \rightarrow K$, которая восстанавливает k с хорошим качеством.

Восстанавливаются следующие релевантные признаки опухоли: ее линейный размер, тип, анатомическая область и полушарие в котором она

находится. В таблице 3.1 указана средняя абсолютная ошибка нахождения линейного размера в вокселях. Для остальных характеристик указана точность классификации.

Для построения моделей f_K использовались линейная регрессия и логистическая регрессия для решения задач регрессии и классификации соответственно. Применялась $L2$ регуляризация. Эти модели были выбраны, так как они демонстрировали наилучшие результаты на кросс-валидации.

Решается задача сегментации	Решаемые задачи классификации	Средняя абсолютная ошибка регрессии линейного размера	Точность классификации типа опухоли	Точность классификации анатомической области	Точность классификации левого-правого расположения
Да	Тип опухоли, анатомическая область, левое-правое расположение	1.64	0.93	0.58	0.81
Да	Тип опухоли, анатомическая область	1.92	0.91	0.54	0.57
Нет	Тип опухоли, анатомическая область, левое-правое расположение	2.4	0.92	0.63	0.57
Да	-	1.59	0.85	0.35	0.58
N/A	N/A	6.12	0.71	0.33	0.51

Таблица 3.1: Качество восстановления характеристик в зависимости от используемой модели. Первые 2 столбца определяют на каких задачах была обучена модель. Последние 4 столбца показывают качество восстановления определенных характеристик. Последняя строка показывает результаты "слепой" модели, использующей пустое множество в качестве признаков.

Как видно из таблицы 3.1, использование многозадачного обучения является важным при построении модели. При решении большего числа релевантных задач в процессе обучения, вектор признаков позволяет лучше решать задачи по восстановлению характеристик.

Можно наглядно показать, что вектора представления содержат информацию о важных характеристиках опухолей, если представления перевести в двумерное пространство с помощью PCA . В этом двумерном пространстве можно наблюдать явную кластеризацию.

Свойство близости объектов и качество ранжирования

Также оценим свойство близости объектов. Это свойство определяет возможность использования l_2 в качестве расстояния между объектами.




Рис. 3.5: График линейных размеров опухолей после применения $2D$ PCA к 64-канальному представлению опухоли. Изменение цвета от синего к красному соответствует изменению размера от меньшего к большему.



Рис. 3.6: График типов опухолей после применения $2D$ PCA к 64-канальному представлению опухолей. Красный, зеленый и синий цвет означают метастазы, менингиомы и шванномы соответственно.

Для оценки свойства близости объектов и качества ранжирования, проведем ранжирование объектов и будем смотреть на сходство характеристик нескольких ближайших объектов. Далее, усредним эти значения по ранжированиям относительно каждого объекта в тестовой выборке. Данный способ оценки качества модели призван отображать реальное использование системы, при котором рассматриваются только несколько ближайших объектов. Далее, усредним эти значения по ранжированиям относительно каждого объекта в тестовой выборке. Количество ближайших объектов будет меняющимся параметром, а в качестве базовой модели рассмотрим случайные ранжирования. Для измерения качества ранжирования будем считать относительное различие линейных размеров:

$$sim_{reg} = \frac{\sum_i^N |L_i - l_{ref}|}{N \cdot l_{ref}} \quad (3.3)$$

Где l_{ref} - линейный размер опухоли относительно которой происходит поиск, а L - массив линейных размеров N ближайших по l_2 опухолей. Принимаемые значения: $[0, +\infty)$, где 0 отвечает наилучшему качеству. Также для определения качества ранжирования будем рассматривать сходство классов:

$$sim_{cl} = \frac{\sum_i^N [K_i == k_{ref}]}{N} \quad (3.4)$$

Где k_{ref} - класс опухоли относительно которой происходит поиск, а K - массив классов N ближайших по l_2 опухолей. Принимаемые значения: $[0, 1]$, где 1 отвечает наилучшему качеству.

Количество ближайших опухолей	Относительное отличие линейных размеров			Сходство типов опухолей			Сходство анатомических областей		
	l1	l2	cos	l1	l2	cos	l1	l2	cos
2	0.217	0.229	0.273	0.881	0.874	0.889	0.311	0.301	0.298
3	0.227	0.24	0.288	0.874	0.864	0.88	0.312	0.296	0.286
5	0.238	0.253	0.312	0.87	0.863	0.876	0.289	0.278	0.284
10	0.267	0.281	0.345	0.854	0.858	0.869	0.268	0.271	0.268
20	0.299	0.314	0.394	0.835	0.833	0.846	0.249	0.249	0.257
2 случайным образом взятые опухоли	1.019			0.563			0.114		

Таблица 3.2: Сходство характеристик у ближайших по евклидовому расстоянию (l_2) и косинусному сходству (cos) опухолей. Сходство характеристик считается по формулам 3.3, 3.4.

Видно, что с увеличением расстояния сходство объектов уменьшается 3.2.1. Так же качество значительно превосходит качество случайной выдачи.

3.2.2 Качественная оценка

Так как в имеющихся у нас данных отсутствует разметка которая явно определяет сходство опухолей, для оценки качества системы помимо количественных критериев приходится опираться и на качественное рассмотрение конкретных примеров работы системы. В данном разделе приведены примеры ранжирования, а также представлен отзыв врачей, которые протестировали систему.

Примеры работы системы

На изображении 3.2.2 изображена шваннома и две ближайшие опухоли в смысле l_2 метрики. Как видно, опухоли имеют одинаково неоднородную форму. Также совпадает тип и локализация опухолей на всех трех картинках.

На изображении 3.2.2 изображена метастаза. Также наблюдается совпадение по типу, локализации и размерам опухолей.

Демонстрация системы врачам

Данная система была продемонстрирована врачам центра «Гамма-нож».

От врачей был получен отзыв, что система может быть полезна в некоторых ситуациях. Например в неспециализированных отделах, где могут




Рис. 3.7: Пример шванномы, и двух ближайших опухолей по l_2 метрике

отсутствовать специалисты по опухолям мозга, система может быть полезна для диагностики заболевания и рассмотрения планов лечения. Так же система может быть полезна для обучения новых специалистов.

В процессе демонстрации было отмечено, что похожие изображения содержали некоторые особенности структуры опухоли. Часто, например, все ближайшие опухоли содержали в себе небольшую некротическую область или были похожей формы. Часть примеров, где ранжирование было проведено некачественно, было связано с некорректными входными данными. Например, вместо МРТ с контрастом было использовано обычное МРТ, что приводит к некорректному найденному представлению (Пример: 3.2.2). Это происходило вследствие того, что при обработке данных приходилось использовать ряд эвристик, которые в некоторых случаях работали неправильно.

Некоторые неудачные случаи поиска связаны с относительно малым размером тестовой выборки. В силу особенностей построения представлений, не было возможности использовать перекрестные предсказания для того чтобы проводить поиск по всем данным. Это значит, что в процессе тестирования нам была доступна лишь малая часть выборки объемом в 400 опухолей, где не всегда были похожие элементы.




Рис. 3.8: Пример метастазы, и ее двух ближайших соседей




Рис. 3.9: Пример неправильной выдачи связанный с использованием модальности T1 без контраста

Глава 4

Заключение

В данной работе мы предложили систему поиска похожих опухолей работающую с трехмерными МРТ снимками мозга. Для этого, был предложен метод построения представления опухоли в пространстве низкой размерности, в котором удобно осуществлять поиск.

Было продемонстрировано, что полученные представления содержат информацию о характерных признаках опухоли, таких как размер, тип и другие. Также было показано, что для решения задачи ранжирования в построенном пространстве можно использовать l_2 расстояние для определения ближайших соседей.

Также было продемонстрировано, что представление лучше всего получать обучаясь сразу на многих задачах, так как это позволяет закодировать больше релевантной информации.

Система была показана врачам, которые подтвердили, что данная разработка может быть полезна в определенных ситуациях. Мы убеждены, что предложенная система может быть использована и для других постановок задачи.

Литература

- [1] J. Gu, Z. Wang, J. Kuen, L. Ma, A. Shahroudy, B. Shuai, T. Liu, X. Wang, and G. Wang, “Recent advances in convolutional neural networks,” *CoRR*, vol. abs/1512.07108, 2015.
- [2] K. Kamnitsas, C. Ledig, V. F. J. Newcombe, J. P. Simpson, A. D. Kane, D. K. Menon, D. Rueckert, and B. Glocker, “Efficient multi-scale 3d CNN with fully connected CRF for accurate brain lesion segmentation,” *CoRR*, vol. abs/1603.05959, 2016.
- [3] L. Hou, D. Samaras, T. M. Kurc, Y. Gao, J. E. Davis, and J. H. Saltz, “Patch-based convolutional neural network for whole slide tissue image classification,” *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [4] H.-C. Shin, H. R. Roth, M. Gao, L. Lu, Z. Xu, I. Nogues, J. Yao, D. Mollura, and R. M. Summers, “Deep convolutional neural networks for computer-aided detection: Cnn architectures, dataset characteristics and transfer learning,” *IEEE Transactions on Medical Imaging*, vol. 35, no. 5, p. 1285–1298, 2016.
- [5] G. Litjens, T. Kooi, B. E. Bejnordi, A. A. A. Setio, F. Ciompi, M. Ghafoorian, J. A. V. D. Laak, B. V. Ginneken, and C. I. Sánchez, “A survey on deep learning in medical image analysis,” *Medical Image Analysis*, vol. 42, p. 60–88, 2017.
- [6] A. S. Razavian, H. Azizpour, J. Sullivan, and S. Carlsson, “Cnn features off-the-shelf: An astounding baseline for recognition,” *2014 IEEE Conference on Computer Vision and Pattern Recognition Workshops*, 2014.
- [7] T. M. Lehmann, M. O. Güld, C. Thies, B. Plodowski, D. Keysers, B. Ott, and H. Schubert, “Irma-content-based image retrieval in medical applications,” vol. 107, pp. 842–6, 02 2004.
- [8] D. Iakovidis, N. Pelekis, E. Kotsifakos, I. Kopanakis, H. Karanikas, and Y. Theodoridis, “A pattern similarity scheme for medical image retrieval,”

IEEE Transactions on Information Technology in Biomedicine, vol. 13, no. 4, p. 442–450, 2009.

- [9] H. Hacid and A. D. Zighed, “A machine learning-based model for content-based image retrieval,” *Artificial Intelligence for Maximizing Content Based Image Retrieval*, p. 171–190.
- [10] C.-R. Shyu, C. E. Brodley, A. C. Kak, A. Kosaka, A. M. Aisen, and L. S. Broderick, “Assert: A physician-in-the-loop content-based retrieval system for hrct image databases,” *Computer Vision and Image Understanding*, vol. 75, no. 1-2, p. 111–132, 1999.
- [11] E. G. Petrakis, “Design and evaluation of spatial similarity approaches for image retrieval,” *Image and Vision Computing*, vol. 20, no. 1, p. 59–76, 2002.
- [12] X. Liu, H. R. Tizhoosh, and J. Kofman, “Generating binary tags for fast medical image retrieval based on convolutional nets and radon transform,” *CoRR*, vol. abs/1604.04676, 2016.
- [13] A. Shah, S. Conjeti, N. Navab, and A. Katouzian, “Deeply learnt hashing forests for content based image retrieval in prostate mr images,” *Medical Imaging 2016: Image Processing*, 2016.
- [14] Y. Chung and W. Weng, “Learning deep representations of medical images using siamese cnns with application to content-based image retrieval,” *CoRR*, vol. abs/1711.08490, 2017.
- [15] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” *CoRR*, vol. abs/1512.03385, 2015.
- [16] “Leksell gamma knife society. patients treated with leksell gamma knife 1968-2016..”
- [17] Y. Zhang and Q. Yang, “A Survey on Multi-Task Learning,” *ArXiv e-prints*, July 2017.
- [18] R. B. Girshick, “Fast R-CNN,” *CoRR*, vol. abs/1504.08083, 2015.
- [19] J. Long, E. Shelhamer, and T. Darrell, “Fully convolutional networks for semantic segmentation,” *CoRR*, vol. abs/1411.4038, 2014.